

Guide de lancement

Hub IA / DiggApp — bot Telegram + interface web

Ce guide explique comment démarrer l'appli au quotidien. Pour les bases du terminal (nano, cd, git...), voir **CHEATSHEET.md** dans le dossier du projet.

1. Prérequis (à vérifier une fois, ou après une longue pause)

1. Ollama doit tourner (moteur IA local). Dans un terminal :

```
ollama serve
```

Ou vérifie qu'il tourne déjà (icône dans la barre de menu macOS). S'il n'est pas lancé, l'appli bascule automatiquement sur Gemini (cloud) si `AI_ENGINE=auto` ou `cloud` dans le `.env`.

2. Les modèles Ollama doivent être téléchargés (une seule fois) :

```
ollama pull qwen2.5vl:7b          # analyse des images/liens
ollama pull nomic-embed-text     # embeddings pour la recherche sémantique
ollama pull llama3.2             # agent conversationnel (recherche par chat)
```

llama3.2 est indispensable pour que la recherche par chat (agent.py) fonctionne en local — qwen2.5vl ne supporte pas le tool calling.

3. Le fichier `.env` doit contenir `TELEGRAM_BOT_TOKEN` (pour le bot) et `GEMINI_API_KEY` (pour le secours cloud). `AI_ENGINE` définit le moteur par défaut (local, cloud ou auto).

2. Lancer le bot Telegram

```
cd ~/Documents/hub-ia
source venv/bin/activate
python3 bot.py
```

&bot! Envoie une photo ou un lien au bot → il l'analyse et le range.

&bot! Envoie un message texte → il cherche dans la collection (via l'agent).

&bot! Commandes dans Telegram : `/start`, `/moteur` (voir/changer local·cloud·auto), `/stats`.

&bot! + C pour arrêter.

3. Lancer l'interface web (DiggApp)

Dans un **autre onglet de terminal** (le bot doit tourner à part si tu veux les deux en même temps) :

```
cd ~/Documents/hub-ia
source venv/bin/activate
python3 web.py
```

Puis ouvre <http://localhost:5001> dans le navigateur.

Port 5001 par défaut car macOS occupe le 5000 avec AirPlay Receiver. Pour libérer le 5000 : Réglages système → Général → AirDrop et Handoff → désactiver « Récepteur AirPlay », puis relancer avec `PORT=5000 python3 web.py`.

Depuis ton téléphone (même Wi-Fi) : l'appli écoute sur 0.0.0.0, donc accessible via l'IP locale du Mac, ex. `http://192.168.1.x:5001` (trouver l'IP : Réglages système → Wi-Fi → Détails).

4. Lancer les deux en même temps

Ouvre 2 onglets terminal (Cmd + T), active le venv dans chacun, puis :

Onglet 1 : `python3 bot.py`

Onglet 2 : `python3 web.py`

5. Commandes utiles

```
# Retraiter les éléments sans catégorie (analyse IA)
venv/bin/python reprocess.py

# Tout retraiter (analyse IA + embeddings) – utile après un
# changement de prompt IA
venv/bin/python reprocess.py --all

# Régénérer uniquement les embeddings depuis les métadonnées
# existantes (rapide, pas d'appel IA) – utile après avoir ajouté
# la recherche sémantique ou changé de modèle d'embedding
venv/bin/python reprocess.py --embeddings-only
```

6. Dépannage rapide

Problème	Solution
(venv) n'apparaît pas dans le prompt	Relance source <code>venv/bin/activate</code> (à refaire à chaque nouvel onglet)
Le bot dit « TELEGRAM_BOT_TOKEN manquant »	Vérifie le <code>.env</code> (<code>nano .env</code>)
Recherche par chat ne répond pas / erreur « does not support tools »	<code>ollama pull llama3.2</code> puis relance <code>ollama serve</code>
Recherche sémantique ne trouve rien sur d'anciens éléments	Lance <code>venv/bin/python reprocess.py --embeddings-only</code>
Port 5001 déjà utilisé	<code>PORT=5002 python3 web.py</code> (ou arrête l'ancien processus)
Tout est lent / timeouts	Vérifie qu'Ollama tourne (<code>ollama list</code>) ; sinon passe en cloud avec /moteur cloud dans Telegram

7. Où sont les données

`bot.db` — base SQLite (toutes les captures + embeddings)

[•ta/captures/](#) — images reçues

[•ta/thumbnails/](#) — miniatures des liens